Projet pour la SAE 5-03
- croissance des enfants -

Le contexte : hôpital

Pour tout les étudiants.

L'INSEE a autorisé certains hôpitaux universitaires à avoir accès à des informations médicales concernant la croissance d'une cohorte représentative d'enfants français. Une équipe de médecins inter-CHU souhaite utiliser ces données pour aider aux diagnostiques de problèmes hormonaux, qui ont un impact sur la croissance de l'enfant. Plus précisément, ils veulent développer un outils automatisé qui analyse la courbe de croissance de l'enfant et qui indique :

- si la croissance d'une fille ressemble plutôt à celle d'un garçon, ou
- si la croissance d'un garçon ressemble plutôt à celle d'une fille, et
- si l'enfant a un score d'IMC qui est supérieur à 35 ou inférieur à 18.

Premier sujet

Pour tout les étudiants.

Pour faire cela, vous aurez accès à la base de données `croissance.csv` et il vous faudra suivre les étapes suivantes :

1. Importer, consulter et prétraiter les données.
2. Réaliser une analyse descriptive qui met en lumière les informations importantes dans la base de données et qui permet de visualiser des informations pertinentes en lien avec la problématique.
3. Mettre les données de chaque individus sur une échelle temporelle commune : 1 ans, 2 ans, ..., 17 ans et 18 ans. Pour cela, vous pourrez utiliser par exemple une méthode d'interpolation par spline cubique.
4. Pour chaque âge, vérifier s'il y a une différence significative entre les filles et les garçons (pour la taille et pour le poids).
5. Ajuster une classification supervisée pour répondre à la problématique.
6. Attester la qualité de votre classification avec une validation croisée.
7. Dans la base de données existantes, déterminer quels sont les enfants pour lesquels il faut vérifier s'ils n'ont pas de problèmes hormonaux.

Le contexte : club de basket

Uniquement pour les non-alternants.

Un des médecins est membre d'un club de basket et il parle de cette base de données à son club avec une idée en tête. Le club décide de contacter l'INSEE et se voit finalement autorisé à acheter un accès aux données anonymisées à des fins commerciales. Leur objectif est de prédire lesquels de leurs jeunes joueurs devraient grandir suffisamment pour atteindre le gabarit d'un joueur de basket professionnel. Le gabarit en question est le suivant :

- pour les garçons, faire plus de 1m85 à 18 ans et peser entre 80 et 110 kg, et
- pour les filles, faire plus de 1m75 à 18 ans et peser entre 60 et 100 kg.

Second sujet

Uniquement pour les non-alternants.

Utilisez comme connaissance la base de données de l'INSEE pour prédire avec une classification supervisée sur la base de données du club (fichier `croissance_club.csv`), quels sont les enfants qui vraisemblablement correspondront au gabarit souhaité.

Consignes

Pour commencer, vous devez **constituer les groupes** (entre 2 et 4 étudiants par groupe) et vous devez en informer votre enseignant par mail. La date limite pour constituer les groupes est le jeudi 25 septembre (23h59). Les données vous seront partagées le vendredi 26 septembre, ce qui correspond à la date de début de ce projet. L'ensemble du groupe travaillera sur le premier sujet (hôpital) et seuls les étudiants non-alternants du groupe travailleront sur le second sujet (club de basket).

Votre travail doit donner lieu à un **rapport d'étude** détaillant 1) les problématiques que vous avez principalement étudié, 2) les approches que vous avez utilisez ainsi que vos résultats, et 3) une conclusion dans laquelle vous détaillerez vos interprétations. Ce rapport ne doit pas faire plus de 8 pages (sans compter la page de garde et les pages blanches) en ce qui concerne le premier sujet, et 3 pages pour le second sujet. Il devra contenir des graphiques, mais avec parcimonie puisqu'aucune annexe ne sera acceptée.

Vous devrez joindre à ce rapport, un **script *R***, avec les commandes que vous avez utilisé. Ce script ne doit pas contenir de partie "brouillon" du code. Il doit s'agir d'une version finale de votre code, qui est à utiliser pour ré-exécuter l'ensemble des approches utilisées et retracer l'ensemble des résultats obtenus. Des commentaires devront être insérés dans votre code de sorte à rendre possible la lecture de votre code.

L'ensemble des documents (rapport et script R) est **à rendre** par mail à emilie.sohier@uca.fr avant le **dimanche** 30 **novembre** (23h59 au plus tard).